Programmazione Algoritmi e Computabilità

2024-2025

Introduzione

Il corso si prefigge l'obiettivo di fornire conoscenze, sia teoriche che pratiche, per la progettazione e implementazione di un'applicazione software, mediante un processo di sviluppo agile e API-led. Si punterà, su piccola scala, al design di algoritmi efficienti e computabili, con le relative strutture dati. Questo primo obiettivo sarà raggiunto studiando la teoria della complessità e della computabilità algoritmica. Su una scala maggiore, si studierà l'architettura software. Questo secondo obiettivo sarà raggiunto impiegando il linguaggio Java, abbinato a middleware, framework e librerie, insieme a tool legati all'IDE Eclipse.

Complessità degli algoritmi

Riprendiamo i concetti di analisi matematica, come la notazione asintotica, per stabilire l'appartenenza del tempo di esecuzione alle classi di complessità. La funzione f(n) rappresenta il tempo di esecuzione o l'occupazione di risorse di un algoritmo su un input di dimensione n. Utilizzeremo questa funzione come astrazione in informatica per nascondere complessità irrilevanti.

La notazione O ("o grande") rappresenta un limite superiore, mentre Ω rappresenta un limite inferiore. La notazione Θ indica limiti sia superiori che inferiori esatti. Le prime due notazioni sono generalmente più facili da trovare.

La notazione O è la più comunemente definita. Una funzione f(n) appartiene alla classe O(g(n)) se esistono due costanti c > 0 e $n_0 > 0$ tali che $f(n) \le cg(n)$ per ogni $n \ge n_0$. In altre parole, a partire da n_0 , la curva analizzata sta sempre al di sotto di cg(n).

La notazione Ω è utilizzata per indicare un limite inferiore. Una funzione f(n) appartiene alla classe $\Omega(g(n))$ se esistono due costanti c > 0e $n_0 \ge 0$ tali che $f(n) \ge cg(n)$ per ogni $n \ge n_0$.

La notazione Θ è utilizzata per indicare limiti sia superiori che inferiori esatti. Una funzione f(n) appartiene alla classe $\Theta(g(n))$ se esistono tre costanti $c_1, c_2 > 0$ se $c_1, c_2 > 0$ se $c_2, c_3 < 0$ tali che $c_1, c_2 < 0$ tali che $c_2, c_3 < 0$ per ogni $c_3 < 0$ per ogni $c_3 < 0$ se $c_3, c_4 < 0$ per ogni $c_3 < 0$ per ogni $c_3 < 0$ per ogni $c_4 < 0$ per ogni $c_5 <$

È importante notare che stiamo facendo un abuso di notazione. In realtà, dovremmo usare il simbolo \in invece di = per indicare l'appartenenza alle classi di complessità. Ad esempio, dovremmo scrivere $f(n) \in O(g(n))$ per indicare che O è un limite superiore asintotico per la funzione appartenente alla sua classe.

Teorema: date due funzioni f(n) e g(n), $f(n) \in \Theta(g(n))$ se e solo se $f(n) = \Theta(g(n))$ e $f(n) = \Theta(g(n))$. (ricontrollare dalle slide)

Ad esempio, $O(n^2)$ e $\Omega(n^2)$ sono limiti inferiori e superiori per qualsiasi polinomio quadratico, aggiustando adeguatamente i parametri del polinomio. Vale anche $\Theta(n^2)$. Un polinomio quadratico è anche $O(n^3)$ ma non $\Theta(n^3)$. Anche quando calcoliamo O, ci conviene stare vicini al sup di Θ .

Proprietà: - transitiva: vale per tutte e tre le notazioni. Si dimostra immediatamente applicando la definizione - riflessiva: vale per tutte e tre. Ogni funzione è limite inferiore e superiore per sé stessa. - simmetria: vale solo per Θ . Se una funzione è nello stesso ordine di un'altra, allora l'altra è nello stesso ordine della prima. - per le altre due vale la simmetria transposta. Il limite superiore per una diventa limite inferiore per l'altra.

Le notazioni di O, Θ e Ω sembrano simili agli ordinamenti totali dei numeri. Non vale però la tricotomia (cioè che debba valere per forza minore, uguale o maggiore). Le funzioni oscillanti rendono difficile il confronto asintotico.

Regole di semplificazione: 1. posso ignorare le costanti moltiplicative nell'ordine 2. la somma di due funzioni avrà O somma tra le O dei due membri (casi di somma: sequenze, branching. Per il branching si conta il costo del ramo più lento. Per le subroutine, si somma il loro costo) 3. il prodotto di funzioni avrà O pari al prodotto degli O dei membri (si applica ai cicli, in base all'O del numero di iterazioni e all'O del corpo)

In caso di dubbi sull'ordine, si applica il teorema dei limiti. Una funzione è dello stesso O di un'altra se il limite all'infinito del loro rapporto è zero. Notare che non vale l'inverso. L'inverso parziale è che il limite del loro rapporto

sia finito se esiste. Se il rapporto è finito, allora il numeratore è Ω del denominatore. Non vale l'inverso, posso solo dire che se esiste allora è una quantità positiva. Se il limite del rapporto è finito positivo, allora vale Θ . Se il limite non esiste, non sono asintoticamente confrontabili.

Limiti temporali

Un problema computazionale ha complessità O(f(n)) (upper bound) se esiste un algoritmo per la sua risoluzione con complessità O(f(n)). Un problema computazionale ha complessità O(f(n)) (lower bound) se ogni algoritmo per la sua risoluzione ha complessità O(f(n)). Riuscendo a dimostrare che un problema ha delimitazione inferiore O(f(n)), e trovando un algoritmo che ha delimitazione superiore O(f(n)), allora si ottiene, a meno di costanti, un algoritmo risolutivo ottimale.

Per la ricerca del minimo in insiemi non ordinati di n elementi la complessità inferiore è $\Omega(n)$ perché è necessario scandire almeno una volta l'intero insieme. Un algoritmo O(n) è dunque ottimo. Il mergesort ha complessità $n \log n$ per un problema $n \log n$ ed è dunque ottimale. Il bubblesort è subottimale perché ha complessità n^2 .

La dimensione dell'input non è il solo criterio in base al quale valutare l'esecuzione degli algoritmi. Distinguiamo caso migliore, peggiore, medio. Dato tempo(I) il tempo di esecuzione dell'algoritmo sull'istanza I, abbiamo

$$\begin{split} T_{worst}(n) &= \max_{\text{istanze } I \text{ di dimensione } n} \{\text{tempo}(I)\} \\ T_{best}(n) &= \max_{\text{istanze } I \text{ di dimensione } n} \{\text{tempo}(I)\} \\ T_{avg}(n) &= \sum_{\text{istanze } I \text{ di dimensione } n} \{\mathcal{P}(I) \text{ tempo}(I)\} \end{split}$$

dove $\mathcal{P}(I)$ è la distribuzione di probabilità dei casi.

Per la ricerca sequenziale (cerca lungo l'intera lista, fermati alla prima istanza trovata), il tempo migliore è 1 (elemento cercato in testa), il peggiore è n (elemento in ultima posizione), media (n+1)/2. Questo vale se assumiamo che le istanze siano equidistribuite e che la probabilità di ogni elemento sia 1/n. Applicando la formula di prima esce la probabilità del caso medio (serie aritmetica).

Spesso il calcolo del caso medio è molto complesso e, in molti casi, si scopre che il caso medio è molto vicino al caso peggiore. Pertanto, è spesso conveniente determinare il limite superiore nel caso peggiore.

La ricerca binaria per liste ordinate si basa su tre indici: inferiore, medio, superiore. Ad ogni passo si confronta l'elemento all'indice medio con il target della ricerca. In caso di differenza, restringiamo la ricerca alla metà corrispondente di lista. In un numero finito di passi l'algoritmo collassa su di un solo elemento. Se esso non è quello cercato, la ricerca fallisce. In alcuni casi può capitare che gli indici si incrocino, e anche in questo caso si può dedurre che l'elemento cercato non sia presente in lista. Il tempo migliore è costante (l'elemento centrale è quello cercato, e viene trovato subito): $\Theta(1)$. Il tempo peggiore si ha quando l'elemento cercato è l'ultimo considerato, o non c'è. Dato che si procede per dimezzamenti della lista, il numero di passi è pari $\log_2 n$ del numero di elementi. Il caso medio è $\log n - 1 + \frac{1}{n}$, simile al caso peggiore.

Strutture dati

Si analizzeranno ora le strutture dati nell'ottica dell'analisi degli algoritmi. Si introduca innanzitutto il concetto di Abstract Data Type. Esso risponde alla domanda "che cosa?", nel senso che definisce la semantica, le operazioni correlate, gli ingressi, le uscite e i vincoli legati al tipo di dati in questione. La struttura dati vera e propria, invece, è una concretizzazione dell'ADT, e risponde alla domanda "come?", fornendo i dettagli implementativi. Nella programmazione a oggetti, gli ADT corrispondono alle interfacce, mentre i tipi concreti corrispondono alle classi. Per fornire un esempio, definiamo astrattamente un dizionario. I dati sono un insieme di coppie chiave / valore. Le operazioni consentite sono l'inserimento (aggiunta di una nuova coppia all'insieme), la cancellazione (rimozione di una coppia dall'insieme data la sua chiave) e ricerca (recuperare una coppia dall'insieme data la chiave). Volendo essere più precisi, potremmo anche definire il tipo di ritorno di ogni operazione, compreso il valore restituito in caso di errori. In Java, la definizione prende la forma seguente:

```
public interface Dizionario {
   public void insert(Object e, Comparable k);
   public void delete(Comparable k);
   public Object search(Comparable k);
}
```

Questa implementazione è non generica (usiamo Object e la versione non generica di Comparable). Volendo sfruttare i tipi generici, invece:

```
public interface Dizionario <E, K extends Comparable <? Super k >> {
    public void insert(E e, K k);
    public void delete(K k);
    public E search(K k);
}
```

Rappresentazioni indicizzate e collegate

Le tecniche di rappresentazione dei dati possono essere divise in due categorie: rappresentazioni indicizzate e rappresentazioni collegate. Il primo raggruppamento memorizza i dati in aree contigue di memoria, come in un array. Questo permette di accedere direttamente ai dati tramite un indice. Di contro, però, la dimensione è fissa, causando spreco di spazio dovuto alla frammentazione interna, da mitigare con riallocazioni frequenti che richiedono un tempo lineare. Il secondo tipo utilizza invece record spazialmente separati, ma collegati logicamente da puntatori. L'effettiva compattezza e lo spazio occupato dipendono dalla specifica implementazione. Esempi di struttura collegata sono la lista semplice, la lista doppiamente collegata e la lista circolare doppiamente collegata. Le rappresentazioni collegate hanno dimensioni variabili, veramente dinamiche. Le aggiunte e le rimozioni sono effettuate a tempo costante. L'accesso dei dati invece richiede un tempo medio lineare, perché è necessariamente sequenziale.

Riprendiamo l'esempio relativo all'implementazione del dizionario. Volendolo costruire come struttura dati collegata, possiamo basarlo sull'array. L'inserimento di una nuova coppia richiede la riallocazione dell'array. Si alloca un nuovo spazio di memoria con lo spazio per un elemento in più. Successivamente lo si riempie copiando il contenuto della versione precedente dell'array finché non si raggiunge l'elemento precedente, in ordine di chiave, rispetto all'elemento da inserire. Si inserisce infine l'elemento nuovo, e dopo di esso tutti gli elementi preesistenti che lo seguono in ordine di chiave. La cancellazione richiede di trovare prima l'indice dell'elemento da cancellare, e in seguito di riallocare l'array con un posto in meno, saltando nella copia l'elemento da scartare. Entrambe le operazioni di inserimento e cancellazione hanno tempo lineare. Dato che l'array è ordinato, la ricerca può essere effettuata in tempo logaritmico sfruttando l'algoritmo di ricerca binaria. Un'implementazione collegata del dizionario può essere generata utilizzando una lista collegata. Le nuove coppie si inseriscono in testa, a tempo costante. L'operazione, infatti, richiede l'aggiornamento di un puntatore (quello della testa, se la lista è vuota) o due puntatori (testa e riferimento al successivo, se la lista non è vuota). L'eliminazione è a tempo lineare perché richiede di scandire sequenzialmente la lista per trovare l'elemento desiderato, e di riscrivere i puntatori per collegare tra loro gli elementi precedente e successivo ad esso. Anche la ricerca è sequenziale e dunque a tempo lineare.

Definiamo la struttura dati astratta per una pila. Si tratta di una semplice sequenza di elementi, e la particolarità sta nella politica d'accesso LIFO ($Last\ In,\ First\ Out$). Possiamo definire operazioni per verificare se sia vuota o meno, per inserire ed eliminare elementi dalla cima, o per osservare tale cima in sola lettura. Anche la pila, come il dizionario, può essere implementata come struttura indicizzata o collegata. Una possibile implementazione indicizzata in Java prende la forma seguente:

```
public interface Pila {
    private int maxSize;
    private int top;
    private Object[] listArray;
}

class LPila implements Pila {
    private Record top;
    private int size;
    ...
}
```

La struttura dati astratta di una coda deve permettere due operazioni (enqueue, "accoda", e dequeue, "rimuovi"), e di accedere in sola lettura all'estremo di interesse. La coda può anche essere bilaterale (nota come deque, ovvero Double-Ended QUEue), e permettere accodamento e scodamento di elementi da entrambi gli estremi. L'implementazione indicizzata di una coda può essere effettuata tenendo due indici, front e rear, per il primo e ultimo elemento della coda all'interno del vettore. Dato che inserimenti e cancellazioni possono lasciare spazi vuoi sia in testa che in coda, conviene interpretare l'array come una struttura circolare e leggerlo "a orologio" lungo un verso stabilito. Questo riduce la necessità di riallocazioni dovute al ricompattamento dei dati. A livello implementativo l'effetto può essere ottenuto usando l'aritmetica modulare nel calcolo degli indici. In questa versione circolare è possibile distinguere tra coda piena e vuota soltanto se è presente almeno uno spazio vuoto tra il primo e l'ultimo elemento. Non è possibile infatti dedurre dagli indici front e rear se l'array sia completamente pieno o completamente vuoto, perché in entrambi i casi la loro posizione si sovrappone. L'implementazione collegata per le

code e le pile è molto semplice da gestire. Tutte le operazioni sono a tempo costante perché si opera sempre e solo sugli elementi in testa (o eventualmente in coda). ## Alberi

Un albero radicato è una coppia T=(N,A) costituita da un insieme N di nodi e da un insieme A di coppie di nodi, dette archi. I dati sono contenuti nei nodi. Le relazioni gerarchiche tra dati sono rappresentate dagli archi che li collegano. Chiamiamo grado di un nodo il suo numero di figli. Chiamiamo foglie i nodi senza figli. Chiamiamo cammino la sequenza di nodi che collega un nodo antenato ad un nodo discendente tramite sole relazioni padre-figlio. La lunghezza di un cammino corrisponde al numero di archi attraversati. Il cammino tra la radice ed un qualsiasi nodo è univoco. La lunghezza di tale cammino è detta profondità del nodo. L'altezza dell'albero è la lunghezza del cammino più lungo possibile al suo interno. Un albero k-ario completo è un albero in cui tutte le foglie hanno la stessa profondità e tutti i nodi interni hanno grado k. Esso ha k^h foglie a profondità h, e $\frac{k^h-1}{k-1}$ nodi interni. Un albero binario completo ha dunque 2^h-1 nodi interni e 2^h foglie.

Rappresentiamo il tipo di dato astratto per un albero:

```
tipo Albero:
dati:
    un insieme di nodi (di tipo nodo) e un insieme di archi
operazioni:
   numNodi() -> intero
        restituisce il numero di nodi presenti nell'albero
    grado(nodo v) -> intero
        restituisce il numero di figli del nodo v
    padre(nodo v) -> nodo
        restituisce il padre del nodo v dell'albero, o null se
        v è la radice
    figli(nodo v) -> (nodo, nodo, ..., nodo)
        restituisce, uno dopo l'altro, i figli del nodo v
    aggiungiNodo(nodo u) -> nodo
        inserisce un nuovo nodo v come figlio di u nell'albero
        e lo restituisce. Se v è il primo nodo ad essere
        inserito nell'albero, esso diventa la radice (e u viene
        ignorato).
    aggiungiSottoalbero(Albero a, nodo u)
        inserisce nell'albero il sottoalbero a in modo che la
        radice di a diventi figlia di u.
    rimuoviSottoalbero(nodo v) -> Albero
        stacca e restituisce l'intero sottoalbero radicato in
        v. L'operazione cancella dall'albero il nodo v e tutti
        i suoi discendenti.
```

Le rappresentazioni concrete degli alberi sono sempre collegate. Per alberi nei quali ogni nodo abbia un numero limitato di figli, possiamo definire un numero limitato di puntatori ai figli. Quando il numero di figli necessita di essere arbitrario, si possono invece tenere un puntatore al primo figlio e un puntatore al fratello successivo.

Gli alberi più usati sono gli alberi binari. Di essi possiamo dare una definizione ricorsiva. L'insieme vuoto \emptyset è un albero binario. Se T_s e T_d sono alberi binari ed r è un nodo allora la terna ordinata (r,T_s,T_d) è un albero binario. In memoria ogni nodo ha un puntatore al padre e due puntatori ai figli. Gli alberi binari si possono utilizzare, tra le altre cose, per rappresentare espressioni matematiche e per costruire classificatori. Definiamo algoritmi di visita gli algoritmi che consentono l'accesso sistematico ai nodi e agli archi di un albero. Gli algoritmi di visita si distinguono in base all'ordine di accesso ai nodi. Analizziamo innanzitutto un algoritmo di visita generico:

```
algoritmo visitaGenerica(nodo r)
    S <- {r}
    while (S != vuoto) do
        estrai un nodo u da S
        visita il nodo u
        S <- S unito {figli di u}</pre>
```

Esso richiede tempo O(n) per visitare un albero con n nodi a partire dalla radice. Un possibile algoritmo non generico è la visita in profondità (DF), che parte dalla radice e visita i nodi di figlio in figlio fino al raggiungimento di una foglia. Risale poi al primo antenato con figli non visitati, e ripete la visita verso le foglie a partire da quei figli. L'algoritmo ha tre varianti. La prima, detta detta preordine o ordine anticipato, visita prima il nodo, poi i sottoalberi sinistro e destro. La seconda, detta inordine o ordine simmetrico, visita prima il sottoalbero sinistro, poi

il nodo base, poi il sottoalbero destro. L'ultima, detta postordine o ordine posticipato, visita prima il sottoalbero sinistro, poi il destro, e infine il nodo.

```
// preordine iterativo
algoritmo visitaDFS(nodo r)
   Pila S
    S.push(r)
    while(not S.isEmpty()) do
        u <- S.pop()
        if(u != null) then
            visita il nodo u
            S.push(figlio destro di u)
            S.push(figlio sinistro di u)
// preordine ricorsivo
algoritmo visitaDFSRicorsiva(nodo r)
    if(r = null) then return
    visita il nodo r
    visitaDFSRicorsiva(figlio sinistro di r)
    visitaDFSRicorsiva(figlio destro di r)
```

Un algoritmo alternativo è la visita in ampiezza (BFS). Partendo dalla radice, l'algoritmo procede visitando i nodi per livelli successivi. Un nodo ad un dato livello è visitabile solo se tutti i nodi del livello superiore sono stati visitati.

```
// versione iterativa
algoritmo visitaBFS(nodo r)
   Coda C
   C.enqueue(r)
   while(not C.isEmpty()) do
        u <- C.dequeue()
        if(u != null) then
            visita il nodo u
            C.enqueue(figlio sinistro di u)
            C.enqueue(figlio destro di u)</pre>
```

Alberi di ricerca

Un albero binario di ricerca (binary search tree, BST) è un albero binario che soddisfa le seguenti proprietà:

- 1. ogni nodo v contiene un elemento elem(v) cui è associata una chiave(v) presa da un dominio totalmente ordinato
- 2. le chiavi nel sottoalbero sinistro di v sono minori o uguali alla chiave(v)
- 3. le chiavi nel sottoalbero destro di v sono maggiori o uguali alla chiave(v)

Gli alberi binari di ricerca sono utilizzati per implementare con efficienza i dizionari, definiti come collezioni di coppie chiave/valore. In questo caso, si chiede che le chiavi da ordinare tramite l'albero siano univoche. In casi d'uso che non richiedano chiavi univoche, possono esserci varie altre regole per ordinare gli elementi.

Su un albero binario generico il costo della ricerca è O(n) indipendentemente dalla strategia applicata, che sia in profondità o in ampiezza. Se l'albero è di ricerca, possiamo partire dalla radice e decidere in che verso muoverci sfruttando l'ordinamento delle chiavi. L'algoritmo di ricerca, formalmente, è:

```
algoritmo search(chiave k) -> elem
  v <- radice di T
  while (v != null) do
      if (k = chiave(v)) then return elem(v)
      else if (k < chiave(v)) then v <- figlio sinistro di v
      else v <- figlio destro di v
    return null</pre>
```

Il caso peggiore si verifica quando la chiave desiderata corrisponde ad una foglia a massima profondità, o quando essa è introvabile. In tal caso, il numero di passi è pari all'altezza dell'albero, e la complessità è O(h), dove h è l'altezza dell'albero. Possiamo mettere in relazione l'altezza h dell'albero con il suo numero n di elementi, per ottenere una stima di complessità in funzione di quest'ultimo. Il caso peggiore corrisponde alla ricerca sull'albero degenere linearizzato, nel quale ogni elemento ha un solo figlio. In questo caso l'albero degenera in una lista

collegata con h = n - 1 elementi, e la ricerca ha dunque complessità O(n) perché richiede la scansione lineare. L'altezza è $h = \Theta(n)$. Il caso migliore è un albero completo bilanciato, in cui ogni elemento ha entrambi i figli, tranne le foglie, e in cui i sottoalberi destro e sinistro di ogni elemento hanno lo stesso numero di membri. In tal caso, l'altezza dell'albero è $h = \Theta(\log(n))$.

Valendo l'ordinamento gerarchico delle chiavi, gli elementi di chiave minima e massima saranno rispettivamente il più a sinistra e il più a destra dell'albero. L'algoritmo per trovare il minimo a partire dalla radice deve procedere verso sinistra fino a una foglia. L'algoritmo per trovare il massimo a partire dalla radice deve procedere verso destra fino a una foglia.

```
algoritmo max(nodo u) -> nodo
    v <- u
    while(figlio destro di v != null) do
        v <- figlio destro di v
    return v

algoritmo min(nodo u) -> nodo
    v <- u
    while(figlio sinistro di v != null) do
        v <- figlio sinistro di v
    return v</pre>
```

Chiamiamo predecessore di un nodo u in un BST il nodo v nell'albero di chiave massima minore o uguale a chiave(u). Chiamiamo successore di un nodo u in un BST il nodo v nell'albero di chiave minima maggiore o uguale a chiave(u). Algoritmicamente, il successore è il minimo del sottoalbero destro, se esiste. Se il sottoalbero destro non esiste, si risale l'albero fino ad un antenato che sia figlio sinistro del proprio nodo padre. Tale nodo padre sarà l'elemento sul cui sottoalbero destro sarà possibile trovare il successore dell'elemento desiderato. Il predecessore è il massimo del sottoalbero sinistro, se esiste. Se il sottoalbero sinistro non esiste, si risale lungo l'albero fino a trovare un antenato che sia figlio destro del proprio nodo padre, e si cerca il predecessore dell'elemento desiderato nel sottoalbero sinistro dell'antenato. Questo algoritmo richiede ovviamente di salvare un riferimento al padre in ogni nodo dell'albero.

```
algoritmo pred(nodo u) -> nodo
  if (u ha un figlio sinistro sin(u)) then
    return max(sin(u))
  while (parent(u) != null e u è figlio sinistro di suo padre) do
    u <- parent(u)
  return parent(u)</pre>
```

L'inserimento in un albero binario di ricerca va effettuato mantenendo la proprietà di ricerca. L'operazione di inserimento è inizialmente simile a quella di ricerca, perché risulta necessario trovare il punto dove inserire ordinatamente il nuovo elemento. Questi è sempre aggiunto come foglia, nel modo meno invasivo possibile. Anche l'inserimento, come la ricerca, ha complessità O(h). La visita in profondità in ordine simmetrico riflette l'ordinamento delle chiavi.

Cancellare mantenendo la proprietà di ricerca è più complesso. Se l'elemento da eliminare è una foglia, può essere rimosso direttamente senza bisogno di altre considerazioni. Se l'elemento da eliminare ha un solo figlio, attacchiamo il figlio dell'elemento da eliminare al padre dell'elemento da eliminare, al posto dell'eliminato. Se l'elemento da eliminare ha due figli, deve essere sostituito con il suo predecessore, e quest'ultimo va poi eliminato secondo le regole dei casi precedenti. Questa procedura funziona perché, per definizione, il predecessore non ha figli destri. In questo modo, la sua eliminazione ricade necessariamente in uno dei primi due casi. La procedura può essere effettuata anche utilizzando l'elemento successore al posto del predecessore.

L'efficienza O(h), come spiegato in precedenza si traduce, in termini di n, in O(n) nel caso peggiore per alberi molto sbilanciati, e in $O(\log(n))$ nel caso peggiore per alberi bilanciati. A tal fine, definiamo il fattore di bilanciamento $\beta(v) = |h(\sin v)) - h(\operatorname{destro}(v))|$. Definiamo un albero bilanciato in altezza se $\forall v$ vale $\beta(v) \leq 1$, completo se $\forall v \mid \beta(v) = 0$ e degenerato in lista se $\beta(v) = h$. Esiste una categoria di alberi, chiamata AVL, che comprende alberi binari bilanciati in altezza, che si auto-aggiustano per rotazione. La rotazione consiste nello spostare la posizione gerarchica di nodi senza però alterare gli archi. Ad esempio, un nodo figlio con un solo figlio può essere promosso a nodo con due figli (il figlio originale e il padre) alzandolo di un livello, e abbassando il padre. La rotazione ha costo O(1). L'inserimento con rotazione richiede di calcolare i fattori di bilanciamento lungo il percorso tra la radice e il nuovo nodo inserito. Successivamente, in caso di criticità solitamente riconoscibili da uno sbilanciamento sopra la soglia di 2, si effettua una singola rotazione nel verso opportuno. Strategie di bilanciamento alternative alla rotazione comprendono lo spostamento e la fusione. Gli alberi rosso-neri utilizzano entrambe queste strategie.

B-Alberi

I B-alberi sono alberi bilanciati utilizzati per memorizzare grandi quantità di dati su disco. Sono particolarmente efficaci per le basi di dati, poiché sono progettati per minimizzare il numero di accessi necessari. Le operazioni fondamentali che possono essere eseguite su un B-albero includono l'inserimento, la cancellazione e la ricerca di dati. Inoltre, per mantenere l'albero bilanciato, vengono eseguite operazioni di bilanciamento come la divisione e l'unione dei nodi.

Ogni nodo di un B-albero contiene più chiavi. I nodi possono contenere fino a n chiavi e avere n+1 figli. Una lettura su disco DiskRead(x) o una scrittura DiskWrite(x) richiede un tempo di accesso proporzionale alla quantità di dati, nell'ordine dei millisecondi, il che è molto più lento rispetto a un'operazione su CPU. Utilizzare un albero molto ramificato permette di ridurre l'altezza dell'albero e, di conseguenza, il numero di accessi alla memoria. Ad esempio, se n + 1 = 1000, è possibile contenere $10^9 - 1$ chiavi in un albero di altezza 2.

Un B-albero T è un albero con radice root[T] che soddisfa le seguenti proprietà:

- 1. Ogni nodo x contiene vari campi, tra cui:
 - n[x]: il numero di chiavi presenti nel nodo.
 - n[x] + 1: il numero di figli del nodo.
 - Altri campi specifici che possono essere recuperati dalle slide.
- 2. Se il nodo non è una foglia, contiene anche i puntatori ai suoi figli.
- 3. Le n(x) chiavi di un nodo interno separano gli intervalli contenenti le chiavi dei sottoalberi, rispettando la proprietà degli intervalli.
- 4. Tutte le foglie si trovano allo stesso livello h, corrispondente all'altezza dell'albero.
- 5. Il numero di chiavi in un nodo è limitato da una costante t, detta grado minimo dell'albero:
 - Ogni nodo, eccetto la radice, ha almeno t-1 chiavi e t figli:

$$n[x] \ge t - 1$$

• Se l'albero non è vuoto, la radice contiene almeno una chiave; se la radice non è una foglia, ha almeno

• Un nodo può contenere al massimo 2t-1 chiavi, nel qual caso è considerato pieno e deve essere suddiviso.

Indicando con k_i una qualsiasi chiave memorizzata nel sottoalbero $C_i[x]$, la proprietà dei sottointervalli ci dice che, per j = 1, ..., n[x] + 1:

$$k_j \le key_i[x] \le k_{i+1}, \quad i = 1, \dots, n[x]$$

I B-alberi minimi, con t = 2, sono noti come alberi 2-3-4.

Ogni B-albero con grado minimo t che contiene N chiavi avrà un'altezza h che sarà al massimo $\log_t \frac{N+1}{2}$, assumendo per convenzione h=-1 per gli alberi vuoti.

Dimostrazione:

- Passiamo alla versione esponenziale della disuguaglianza: $h \leq \log_t \frac{N+1}{2} \to N \geq 2t^h 1$.
- Se l'albero è vuoto, h = -1 e $N = 0 \ge 2t^{-1} 1$ (caso base).
- Supponiamo che l'albero non sia vuoto, con radice r e $h \ge 0$. Sia m_i il numero di nodi al livello i-esimo. Allora:

 - $-m_1=n[root]+1\geq 2$ (figli della radice che ha almeno una chiave) $-m_i\geq tm_{i-1}$ per i>1, quindi $m_i\geq t^{i-1}m_1\geq 2t^{i-1}$ (ogni nodo ha almeno t figli)

Quindi, per le chiavi:

$$N = \sum_{x} n[x]$$

$$= n[root] + \sum_{i=1}^{h} \sum_{x \text{ di livello } i} n[x]$$

$$\geq 1 + \sum_{i=1}^{h} 2t^{i-1}(t-1)$$

(che è una serie geometrica)

$$= 1 + 2(t-1)\frac{t^h - 1}{t-1}$$
$$= 1 + 2(t^h - 1) = 2t^h - 1.$$

L'altezza di un B-albero è $O(\log_t N)$, dello stesso ordine di grandezza di $O(\log_2 N)$ degli alberi binari, ma per $50 \le t \le 2000$ la notazione nasconde un fattore di riduzione compreso tra 5 e 11.

Operazioni Elementari e Convenzioni

Le operazioni elementari su un B-albero seguono alcune convenzioni fondamentali:

- la radice dell'albero è sempre mantenuta in memoria;
- i nodi passati come parametri alle funzioni sono sempre letti dalla memoria.

Operazioni Definite

Le operazioni principali definite per un B-albero includono:

- costruttore di un albero vuoto (BTree): inizializza un B-albero vuoto
- search: cerca una chiave specifica all'interno dell'albero
- insert: inserisce una nuova chiave nell'albero
- delete: rimuove una chiave esistente dall'albero

Procedure Ausiliarie

Per supportare le operazioni principali, vengono utilizzate tre procedure ausiliarie:

- SearchSubtree: Cerca una chiave all'interno di un sottoalbero specifico.
- SplitChild: Divide un nodo figlio pieno in due nodi, ridistribuendo le chiavi e aggiornando i puntatori ai figli.
- InsertNonfull: Inserisce una chiave in un nodo che non è pieno, mantenendo l'albero bilanciato.

Queste procedure ausiliarie sono essenziali per garantire che l'albero rimanga bilanciato e che le operazioni di inserimento e cancellazione siano efficienti.

Implementazioni e complessità

```
Il costruttore BTree:
```

BTree(t)

```
root[T] <- nil</pre>
ha complessità O(1).
L'operazione di ricerca Search:
Search(T,k)
    if root[T] = nul then return nil
    else return SearchSubtree(root[T], k)
si basa sull'operazione ausiliaria SearchSubTree:
SearchSubtree(x, k)
    i <- 1
    while i <= n[x] and k>key_i[x] do
        i <- i+1 // ricerca dell'indice i tale che k <= key_i [x]
                  // invariante: proprietà degli intervalli
        if i <= n[x] and k = key_i [x] return x, i // successo
    else if leaf[x] return nil // ricerca senza successo
    else // ricerca ricorsiva nel sottoalbero c i[x]
        DiskRead(c i[x])
```

return SearchSubtree(c_i[x], k)

che prende un nodo come argomento. Il costo complessivo va calcolato sommando il costo ricorsivo della discesa al costo additivo della ricerca sequenziale o binaria sulle chiavi del nodo considerato. La versione binaria prende la seguente forma:

```
SearchSubtree(x, k)
  i <- 1, j <- n[x]+1
  while i < j do
      if k <= key_floor((i+j)/2) [x] then j <- floor((i+j)/2)
      else i <- floor((i+j)/2) + 1
  if leaf[x] return nil // ricerca senza successo
  else // ricerca ricorsiva nel sottoalbero c_i[x]
      DiskRead(c_i[x])
    return SearchSubtree(c_i[x], k)</pre>
```

Il numero di DiskRead è, al più, uguale all'altezza h dell'albero, ed è quindi $O(h) = O(\log_t N)$ con N chiavi nel B-albero. Il tempo T di CPU per la ricerca è $T = O(th) = O(t\log_t N)$. Usando la ricerca dicotomica, il costo è $O(\log th)$ e complessivamente $O(\log t\log_t N) = O(\log N)$.

L'inserimento di una chiave in un B-albero segue un processo specifico. Non si aggiunge mai ai nodi interni. Le chiavi vengono inserite solo nelle foglie. Questo perché l'inserimento nei nodi interni creerebbe sottoalberi, complicando la gestione dell'albero. Una chiave viene inserita solo in una foglia. Se la foglia non è piena, l'inserimento avviene direttamente. Se la foglia è piena, il nodo viene diviso. Se la foglia è piena, viene divisa in due nodi più piccoli. L'elemento centrale viene spostato nel nodo padre, mantenendo l'ordinamento delle chiavi. La complessità dell'inserimento è O(h), dove h è l'altezza dell'albero. Questo è dovuto al fatto che ogni operazione di inserimento richiede un numero costante di accessi al disco (DiskRead e DiskWrite) tra due chiamate consecutive di insertNonFull. Consideriamo, ad esempio, un B-albero con grado minimo t=4. In questo caso, il numero di chiavi in un nodo è compreso tra 3 e 7 (limite inferiore t-1, limite superiore 2t-1). Se la radice è piena, si crea una nuova radice e si sposta la vecchia radice come sua figlia. Il nodo figlio viene quindi diviso in due nodi più piccoli, spostando l'elemento centrale nella nuova radice. Questo processo mantiene l'ordinamento delle chiavi, poiché le chiavi sono già ordinate.

La cancellazione di una chiave può lasciare un nodo con un numero di chiavi inferiore al minimo. In questo caso, si uniscono due nodi fratelli, inserendo come intermezzo la chiave intermedia presa dal padre. Questa operazione è speculare alla divisione (split). Le operazioni di inserimento e cancellazione in un B-albero sono progettate per mantenere l'albero bilanciato e ordinato, garantendo così un accesso efficiente ai dati. La complessità di queste operazioni è O(h), dove h è l'altezza dell'albero, grazie a un numero costante di accessi al disco tra le chiamate consecutive delle procedure ausiliarie.

Tabelle hash

Un'altra struttura dati concreta per il tipo astratto Dizionario è la tabella hash o tavola ad accesso diretto. L'idea alla base delle tabelle hash è mappare direttamente la chiave all'indice di un array. Questo è semplice se le chiavi sono univoche e numeriche, purché non superino le dimensioni dell'array. I costi associati all'accesso a diverse strutture dati variano: una lista e un albero di ricerca non bilanciato hanno un costo di O(n), mentre un albero di ricerca bilanciato ha un costo di $O(\log n)$. Le tabelle hash, invece, offrono un costo di O(1).

Di seguito è riportato lo pseudocodice dell'implementazione di una tabella hash.

```
classe TavolaAccessoDiretto implementa Dizionario:
dati:
    un array v di dimensione m>=n in cui v[k] = elem se c'è un elemento con
    chiave n nel dizionario, e v[k] = null altrimenti.
    Le chiavi k devono essere nell'intervallo [0, m-1].

operazioni:
    insert(elem e, chiave k)
        v[k] <- e
    delete(chiave k)
        v[k] <- null
    search(chiave k) -> elem
        return v[k]
```

Tutte e tre le operazioni hanno complessità temporale lineare: T(n) = O(1). Il fattore di carico α è definito come il rapporto tra il numero di elementi n e la capacità m della struttura dati:

$$\alpha = \frac{n}{m}$$

La funzione hash h mappa un dominio totalmente ordinato U (che può includere chiavi non numeriche) a un intervallo [0, m-1]. L'elemento con chiave k viene posizionato in v[h(k)]. Un problema comune è la gestione delle

collisioni: è difficile trovare una funzione $hash\ h$ che sia veramente univoca $(hash\ perfetta)$, dove $u \neq v$ implica $h(u) \neq h(v)$. Questo è possibile solo se il numero di elementi in U è minore o uguale a m, permettendo a h di essere iniettiva. Solitamente, la funzione hash è suriettiva. Una collisione si verifica quando si inserisce un elemento la cui chiave ha un valore hash uguale a quello di un elemento già memorizzato. Per ridurre le collisioni, è possibile limitare l'insieme delle chiavi.

Per ottenere un dizionario con un tempo di accesso veramente O(1), è necessario disporre di una funzione hash che sia perfetta, ovvero che mappi ogni chiave a un indice univoco senza collisioni, e calcolabile in tempo O(1). Se queste condizioni non sono soddisfatte, è importante che la funzione hash garantisca almeno l'uniformità semplice, ovvero che ogni elemento abbia la stessa probabilità di causare una collisione.

Le funzioni hash crittografiche sono progettate per essere unidirezionali, il che significa che è difficile risalire al messaggio originale a partire dal valore hash. Queste funzioni sono resistenti alle collisioni, alla preimmagine (è difficile trovare un messaggio che corrisponda a un dato valore hash) e alla seconda preimmagine (è difficile trovare due messaggi diversi che producano lo stesso valore hash). # Algoritmi di ordinamento

Gli algoritmi di ordinamento possono essere classificati in base alla loro complessità temporale e al tipo di operazioni che utilizzano. Tipicamente, gli algoritmi di ordinamento hanno una complessità di $O(n^2)$ o $O(n \log n)$ quando sono basati sul confronto. Esistono anche algoritmi di ordinamento che non si basano sul confronto e che possono raggiungere una complessità di O(n).

MergeSort

MergeSort è un algoritmo di ordinamento che utilizza la strategia divide et impera. L'idea è scomporre il problema iniziale in sottoproblemi più piccoli, risolvere tali sottoproblemi ricorsivamente e poi unire le soluzioni. In pratica, l'algoritmo dimezza l'array, applica l'algoritmo ai sottoarray e poi fonde le sottosequenze ordinate. L'algoritmo continua a dividere finché non rimangono solo array di 1 o 2 elementi. Ad esempio, partendo dall'array [52804719326], la divisione procede come segue:

```
[528047] [19326]
[528] [047]
[52] [8]
[5] [2]
```

Una volta che l'array è stato completamente suddiviso, inizia la fase di fusione (merge). Ad esempio, partendo dai sottoarray 5 2, la fusione procede come segue:

```
[25] [8]
[258]
```

La fusione avviene scorrendo le due liste con due indici, confrontando le coppie di elementi nelle due liste e scegliendo quale elemento mettere per primo nell'*array* fuso. Questa procedura funziona correttamente solo se gli *array* di partenza sono già ordinati.

Ecco lo pseudocodice per l'algoritmo MergeSort operando su un array di dimensione n:

La procedura Merge funziona come segue:

- 1. Estrai ripetutamente il minimo tra gli elementi dei sottoarray A[p..q] e A[q+1..r] e copialo in un array di output C fino a quando uno dei due sottoarray non si svuota.
- 2. Copia gli elementi rimasti dal sottoarray non svuotato in C.

L'algoritmo Merge Sort non opera in loco, poiché richiede un array di output C. La complessità temporale della procedura Merge è lineare, ovvero $\Theta(n)$, dove n = r - p + 1.

```
merge(A,p,q,r)
    n_1 <- q - p + 1
    n_2 <- r - q
    for i <- 1 to n_1 do
        L[i] <- A[p+i-1]
    for j <- 1 to n_2 do</pre>
```

```
R[j] <- A[q+j]
L[n_1 + 1] <- R[n_2 + 1] <- infinity
i <- j <- 1
for k <- p to r do
    if L[i] <= R[j] then
        A[k] <- L[i]
        i <- i + 1
else
        A[k] <- R[j</pre>
```

I costi del merge possono essere suddivisi in tre componenti principali. L'assegnamento di q è lineare, mentre la divisione risulta poco costosa. Il passo più oneroso è rappresentato dalla fusione.

Il numero di confronti può essere espresso dalla seguente equazione:

$$T(n) = d(n) + 2 \cdot T\left(\frac{n}{2}\right) + c(n)$$

dove d'appresenta il costo di divisione, che è $\Theta(1)$, e c(n) rappresenta il costo di fusione, che è $\Theta(n)$. Di conseguenza, il costo totale rientra nella classe $\Theta(n)$.

Applicando il teorema Master con a = 2 e b = 2, si ottiene

$$T(n) = \Theta(n \log n).$$

Pertanto, il *MergeSort* risulta ottimale dal punto di vista temporale, ma non lo è dal punto di vista della memoria, poiché non può essere eseguito in loco.

QuickSort

QuickSort è un algoritmo di ordinamento che divide il problema in due sottoproblemi scegliendo un elemento pivot e separando gli elementi maggiori e minori rispetto a questo pivot.

La versione non in loco di QuickSort funziona come segue:

- 1. Scegli un elemento x (il pivot) dall'array A.
- 2. Partiziona A rispetto a x calcolando due sotto-array:
 - A_1 contiene tutti gli elementi di A che sono minori o uguali a x.
 - A_2 contiene tutti gli elementi di A che sono maggiori di x.
- 3. Se A_1 contiene più di un elemento, applica QuickSort a A_1 .
- 4. Se A_2 contiene più di un elemento, applica QuickSort a A_2 .
- 5. Copia la concatenazione di A_1 e A_2 in A.

La partizione in loco di QuickSort avviene scorrendo l'array da sinistra verso destra e da destra verso sinistra. Durante questa scansione, ci si ferma su un elemento maggiore del pivot quando si scorre da sinistra verso destra, e su un elemento minore del pivot quando si scorre da destra verso sinistra. A questo punto, si scambiano i due elementi e si continua finché gli indici non si incrociano. Una volta che gli indici si incrociano, si pongono i due sotto-array a sinistra e a destra del pivot.

Per implementare QuickSort in loco, è necessario definire una funzione ausiliaria chiamata Partition(A, i, f):

- 1. x = A[i] (partiziona A[i...f] intorno al pivot A[i]).
- 2. Inizializza inf = i e sup = f + 1.
- 3. Esegui un ciclo infinito:
 - Incrementa inf finché inf $\leq f$ e $A[\inf] \leq x$.
 - Decrementa sup finché $A[\sup] > x$.
 - Se inf < sup, scambia $A[\inf]$ e $A[\sup]$.
 - Altrimenti, esci dal ciclo.
- 4. Scambia A[i] e $A[\sup]$.
- 5. Restituisci sup.

Alla riga 5, la condizione è sufficiente perché l'indice non uscirà mai dall'array senza prima incontrare il pivot e bloccarsi. La riga 8 posiziona il pivot al centro. La riga 9 restituisce il nuovo pivot. Il tempo di esecuzione di QuickSort è $\Theta(n)$ ad ogni iterazione, poiché vengono effettuati n-1 confronti tra gli elementi e il pivot.

Ora possiamo scrivere l'implementazione completa di QuickSort:

```
QuickSort(A, i, f)
   if (i >= f) then return
```

```
m = Partition(A, i, f)
QuickSort(A, i, m-1)
QuickSort(A, m+1, f)
```

Questa versione di QuickSort non è stabile, poiché l'albero delle chiamate ricorsive può essere sbilanciato a seconda della distribuzione dell'array di origine rispetto al pivot. Una possibile ottimizzazione è la scelta dell'elemento mediano come pivot iniziale.

Caso peggiore

Nel caso peggiore, il pivot è il minimo o il massimo dell'array (array ordinato direttamente o inversamente). Il numero di confronti è:

$$T(n) = \Theta(n) +$$

Utilizzando il metodo dell'albero della ricorsione, sommiamo i nodi di tutti i livelli e notiamo che sono:

$$T(n) = \sum_{i=2}^{n} i + \mathcal{K} = \Theta(n^2)$$

Caso migliore

Nel caso migliore, l'albero di ricorsione è perfettamente bilanciato (due sottoalberi di dimensione non maggiore di n/2), e l'algoritmo ha un costo coincidente a quello del MergeSort (pseudolineare in n):

$$T(n) = \Theta(n \log n)$$

Caso medio

Per ottenere un'approssimazione del caso medio di *QuickSort*, possiamo scegliere un *pivot* dall'array in modo casuale. Questo riduce la possibilità di un comportamento peggiore del previsto. Possiamo ulteriormente migliorare la scelta del *pivot* selezionando il mediano di un sottoinsieme di elementi estratti casualmente.

Nel caso di una sola estrazione, ogni elemento ha una probabilità di $\frac{1}{n}$ di essere scelto come pivot. Il numero C di confronti nel caso atteso è dato da:

$$C(n) = \sum_{a=0}^{n-1} \frac{1}{n} \left[n - 1 + C(a) + C(n-a-1) \right] = n - 1 + \sum_{a=0}^{n-1} \frac{2}{n} C(a)$$

dove a e (n-a-1) sono le dimensioni dei sottoproblemi risolti ricorsivamente. C(a) e C(n-a-1) danno luogo alla stessa sommatoria perché entrambe le chiamate alternano partizioni buone e cattive. La relazione di ricorrenza $C(n) = n - 1 + \sum_{a=0}^{n-1} \frac{2}{n} C(a)$ ha soluzione $C(n) \le 2n \log n$, quindi:

$$T(n) = O(n \log n)$$

Non possiamo usare Θ perché la soluzione è ottenuta per integrazione e non è dunque possibile ottenere un limite stretto.

Java implementa QuickSort, MergeSort e HeapSort come funzioni nelle classi Arrays e Collections. Queste implementazioni sono ottimizzate per garantire prestazioni efficienti e affidabili in una vasta gamma di scenari.

Algoritmi lineari

Gli algoritmi di ordinamento che funzionano in tempo lineare in n hanno condizioni particolari di applicabilità. Tra questi, troviamo l'IntegerSort (o CountingSort), il BucketSort e il RadixSort.

IntegerSort

L'Integer Sort funziona esclusivamente su vettori X di numeri interi di cui siano noti il minimo e il massimo. I valori devono essere compresi nell'intervallo [1,k]. L'algoritmo costruisce un array di appoggio Y di k elementi, inizializzato a zero. Scorrendo X, per ogni occorrenza del numero n, incrementa di uno l'n-esima cella di Y. Al termine dello scorrimento, ricostruisce X copiando al suo interno gli indici di Y, ognuno un numero di volte pari al numero contenuto nella rispettiva cella.

Osserviamo lo pseudocodice:

```
IntegerSort(X, k)
1. sia Y un array di dimensione k
2. for i = 1 to k
3.
      Y[i] = 0
4. for j = 1 to n
5.
      Y[X[j]] = Y[X[j]] + 1
6. k = 1
7. for i = 1 to k
8.
      while Y[i] > 0
         X[k] = i
9.
         Y[i] = Y[i] - 1
10.
11.
         k = k + 1
```

Analizziamo la complessità temporale dell'algoritmo: - Il tempo per inizializzare Y a zero è O(k). - Il tempo per contare gli indici è O(n). - Il ciclo esterno della ricostruzione è compatto e viene eseguito k volte. - I cicli interni sono indefiniti, ma le iterazioni totali saranno n.

In sintesi, l'algoritmo ha una complessità temporale di O(k+n), che si approssima a O(n) se $k \le n$. Non essendo basato sul confronto, non ha il limite inferiore $\Omega(n \log n)$.

Stabilità degli algoritmi

Un algoritmo è definito *stabile* se preserva l'ordine iniziale tra elementi con la stessa chiave. La stabilità è particolarmente utile per ordinamenti su più chiavi. Applicando algoritmi stabili, è possibile ordinare prima per una chiave e poi per un'altra; se l'algoritmo non è stabile, gli elementi rimarranno ordinati solo per l'ultima chiave applicata.